HW2 專案報告：以多元線性回歸進行預測分析（CRISP-DM）

課程：物聯網 HW2 ・ 方法：多元線性回歸（Multiple Linear Regression）、特徵選擇、預測區間 ・ 流程：CRISP-DM ・ 網頁：https://annn1029.github.io/HW2/ ・ 原始碼：https://github.com/annn1029/HW2

> 本文件用途：作為 NotebookLM 的來源，說明本專案的資料、分析方法與結果，以便搜尋與比較網路上「同主題」的解法。本專案包含兩個資料集：**A. 伊斯坦堡公寓房價預測**、**B. 人機互動中使用者對 AI 的信任分數預測**。

1. 作業要求摘要

- 從 Kaggle 選擇特徵數超過 13 個的公開資料集，使用線性回歸（簡單、多元或自迴歸）進行預測。
- 必須執行**特徵選擇（Feature Selection）**與**模型評估（Model Evaluation）**，並提供含**信賴區間或預測區間**的預測圖。
- 依 CRISP-DM 六階段說明：Business Understanding、Data Understanding、Data Preparation、Modeling、Evaluation、Deployment。
- 以 GitHub 與網頁（GitHub Pages）繳交；報告中標示「GPT 輔助內容」與「NotebookLM 摘要」。

2. 資料集總覽

	資料集 A：伊斯坦堡公寓房價	**資料集 B：人機互動信任分數**
Kaggle 來源	Istanbul Apartment Prices 2026（作者 brahimenesulusoy）kaggle.com/datasets/brahimenesulusoy/istanbul-apartment-prices-2026	Human-AI Interaction（作者 eshaalnmalik）kaggle.com/datasets/eshaalnmalik/human-ai-interaction
規模	24,767 筆、30 欄	10,100 筆、21 欄（20 個特徵）
目標變數	`price`（土耳其里拉），建模時取 log(price)	`latent_trust_score`（約 38–100，近似常態）
主要特徵	淨面積、總面積、房間數、客廳數、衛浴數、樓層、總樓層、屋齡、行政區（38 區）、暖氣、產權、屋況、家具、使用狀態、是否在社區內、管理費、方位、可否貸款	年齡、教育程度、技術經驗、認知負荷、AI 使用經驗、模型準確率、可解釋性、偏誤程度、決策延遲、錯誤率、互動頻率、介面複雜度、回饋品質、信任歷史、推翻 AI 次數、任務風險、應用領域、時間壓力、文化背景、法規嚴格度
研究問題	哪些房屋屬性決定伊斯坦堡公寓的售價？能否提供合理的價格範圍？	哪些使用者、系統與情境因素決定人對 AI 的信任？

3. 資料集 A：伊斯坦堡公寓房價

Business Understanding

伊斯坦堡房價在高通膨下劇烈波動，買方、賣方與仲介需要透明、可解釋的估價工具。目標是以房屋屬性預測售價，並以預測區間表達單一物件的不確定性。成功標準：測試集 R^2（log）≥ 0.75、95% 預測區間覆蓋率接近 95%。

Data Understanding

- 價格極度右偏（中位數約 675 萬 TRY，最大值 115 億為輸入錯誤），取 log 後接近常態。
- `price_per_sqm` 由價格除以面積得到，屬於**資料洩漏（data leakage）**，必須刪除。
- 6 個欄位缺值超過 50%；存在不合理值（房間數 114、總樓層 450、屋齡 400）。
- 行政區之間房價中位數差距可達 5 倍以上，地段是最重要因素。

Data Preparation

- 刪除洩漏欄位、ID、時間戳記、高缺值欄位（complex_name）、高基數欄位（neighborhood，583 類）。
- 價格只保留 0.5%–99.5% 分位數；設定合理範圍（25 ≤ 淨面積 ≤ 500、淨面積 ≤ 總面積、房間 ≤ 10 等）。清理後 24,403 筆（刪除 1.5%）。
- 數值缺值以中位數填補並加缺值旗標；類別缺值補上 Missing；稀有類別合併為 Other。
- 衍生特徵：log_net_sqm、floor_ratio（樓層/總樓層）、faces_south、n_directions、has_maint_fee。
- One-hot 編碼（drop_first），22 個特徵群組展開為 70 個欄位；訓練/測試 80/20。

Modeling 與特徵選擇

- 基準：簡單線性回歸 log(price) ~ log(net_sqm)。
- 全特徵多元線性回歸（OLS，statsmodels）。
- 特徵選擇三種方法：**Forward Stepwise（以 AIC 為準則，以特徵群組為單位，ΔAIC < 2 停止）**、**RFE（保留 30 個欄位）**、**LassoCV（L1 正則化，5-fold CV 選 α）**。
- Stepwise 選入順序：行政區 → 總面積 → 屋齡 → 暖氣 → 產權 → 是否在社區內 → 淨面積 → 衛浴數 → … ；刪除 floor_missing、total_floors、faces_south、n_directions。

Evaluation

模型	R^2（log）	Adj R^2	RMSE（log）	價格 MedAPE	CV5 R^2	欄位數
簡單線性回歸（log_net_sqm）	0.257	0.257	0.638	41.4%	0.258	1
多元線性回歸（全特徵）	0.803	0.800	0.329	19.5%	0.800	70
多元線性回歸（Stepwise-AIC，最終）	**0.803**	**0.800**	**0.329**	**19.5%**	**0.800**	**66**
多元線性回歸（RFE 30）	0.734	0.732	0.382	22.4%	0.727	30
LassoCV	0.803	0.800	0.329	19.6%	—	67

- 95% 預測區間在測試集的實際覆蓋率為 **94.7%**；殘差大致對稱但尾部略厚；數值特徵 VIF 皆小於 10。

- RFE 以單一欄位為單位刪除，會把行政區 dummy 拆開，因此表現較差；以群組為單位的 Stepwise 與 Lasso 結果一致。
- 限制：未使用街區層級資訊、未加入交互作用項；exp(ŷ) 轉回價格得到的是中位數預測。

4. 資料集 B：人機互動信任分數

Business Understanding

AI 系統能否被採用取決於使用者是否信任它；過度不信任或過度信任都有風險。目標是以使用者特徵、AI 系統特性與使用情境預測信任分數，找出真正影響信任的因素。成功標準：測試集 $R^2 \geq 0.65$、特徵選擇後模型更精簡且表現不下降、95% 預測區間覆蓋率接近 95%。

Data Understanding

- 每個欄位約有 2% 隨機缺值（若整列刪除會損失約 35% 資料）；100 筆完全重複；error_rate 有 150 筆負值。
- 目標分數平均 70.5、標準差 9.1、上限 100，不需取 log。
- 與目標相關最高：trust_history（$r \approx 0.49$），其次為模型準確率、偏誤（負）、錯誤率（負）、回饋品質；類別特徵中只有介面複雜度有明顯差異。
- model_accuracy 與 error_rate 相關係數 −0.97（幾乎是 1 − 對方）。

Data Preparation

- 刪除重複列與目標缺值列，error_rate 截斷至 ≥ 0，清理後 9,800 筆。
- **先切分 80/20 再填補缺值**（數值用訓練集中位數、類別用訓練集眾數），避免資料洩漏。
- 類別變數 one-hot 編碼，20 個特徵展開為 30 個欄位。

Modeling 與特徵選擇

- 基準：簡單線性回歸 trust ~ trust_history；全特徵多元線性回歸；Forward Stepwise-AIC、RFE（10 個欄位）、LassoCV。
- Stepwise 選入順序：trust_history → ui_complexity → bias_level → feedback_quality → model_accuracy → cognitive_load → error_rate → override_frequency → regulatory_strictness。
- 被刪除：年齡、技術經驗、可解釋性、決策延遲、互動頻率、時間壓力、教育程度、AI 使用經驗、任務風險、應用領域、文化背景。
- 最終係數（未取 log，即分數變化）：trust_history +15.0；低複雜度介面 +9.9、中複雜度 +4.9（相對高複雜度）；bias_level −10.1；feedback_quality +10.1；model_accuracy +10.5；cognitive_load −5.1；error_rate −9.7。

Evaluation

模型	R^2	Adj R^2	RMSE	MAE	CV5 R^2	欄位數
簡單線性回歸（trust_history）	0.217	0.216	7.94	6.34	0.227	1
多元線性回歸（全特徵）	0.694	0.690	4.96	3.91	0.690	30
多元線性回歸（Stepwise-AIC，最終）	**0.695**	**0.693**	**4.96**	**3.92**	**0.691**	**10**
多元線性回歸（RFE 10）	0.695	0.693	4.96	3.92	0.691	10
LassoCV	0.695	0.691	4.95	3.91	—	25

- 95% 預測區間覆蓋率 **95.4%**；殘差近似常態、變異一致。
- model_accuracy 與 error_rate 的 VIF ≈ 16（共線性），兩者個別係數不宜單獨解讀，應視為一組共同效果。
- RFE 選出的欄位與 Stepwise 完全相同；人口統計與情境特徵對信任幾乎沒有影響。
- 限制：資料為合成資料、分數在 100 被截斷；約 30% 變異可能來自非線性或交互作用。

5. 共同的方法與部署

- **信賴區間 vs 預測區間**：以 statsmodels `get_prediction().summary_frame()` 計算。CI 描述平均值的不確定性（只含係數誤差）；PI 描述單一新觀測值的不確定性（再加上殘差變異 σ^2），因此較寬。
- **預測圖**：(1) 測試集隨機 150 筆依預測值排序，畫出預測值、實際值、95% CI 與 PI 帶；(2) 效果圖：A 為三個行政區的價格對面積曲線，B 為三種介面複雜度下信任對模型準確率的曲線，皆含 CI／PI 帶。
- **模型診斷**：殘差對預測值圖、Q-Q 圖、殘差分布、VIF、5-fold 交叉驗證。
- **部署**：係數、共變異數矩陣與殘差變異匯出為 JavaScript，在 GitHub Pages 網頁上即時計算 $\hat{y} = x^T\beta$ 與 95% PI = $\hat{y} \pm t \cdot \sqrt{(\sigma^2 + x^T Cov(\beta) x)}$；網頁以下拉選單切換兩個資料集。
- 工具：Python（pandas、numpy、statsmodels、scikit-learn、matplotlib、seaborn）、Jupyter、GitHub Pages。

6. 供 NotebookLM 搜尋與比較的主題

- House price prediction with multiple linear regression；log transformation of house prices；hedonic pricing model。
- Istanbul / Turkey real estate price prediction with machine learning；location (district) effects on housing prices。
- Feature selection for linear regression：stepwise AIC、recursive feature elimination (RFE)、Lasso；grouped dummy variable selection。
- Prediction interval vs confidence interval in regression；prediction interval coverage。
- Data leakage in feature engineering（例如 price per square meter）；imputation after train/test split。
- Trust in AI / human-AI interaction：factors affecting user trust（accuracy、bias、explainability、UI complexity、feedback）；trust calibration。
- Multicollinearity and VIF（accuracy vs error rate）；CRISP-DM process for data mining projects。

可以問 NotebookLM 的問題

- 網路上其他人預測房價時，用了哪些特徵選擇方法與模型？評估指標和 R^2 大約多少？與本專案相比如何？
- 相關研究認為影響使用者信任 AI 的主要因素有哪些？與本專案資料集 B 的結果是否一致？
- 線性回歸以外，同主題常見的改進方法有哪些（例如樹模型、交互作用、正則化）？

7. GPT 輔助內容（與 AI 助理的對話摘要）

> **【GPT 輔助內容】**以下為作者與 AI 助理（本作業使用 Claude）對話過程的摘要，依時間順序整理。程式與報告由 AI 協助產生，作者負責提供資料、檢閱、執行與決策。

階段	作者的需求	AI 助理的協助與產出
1. 閱讀作業與規劃	閱讀 HW2 作業要求，規劃接下來要做什麼	檢查作者提供的伊斯坦堡房價資料（24,767 筆、30 欄），確認特徵數符合要求；指出 `price_per_sqm` 會造成資料洩漏、價格右偏需取 log、多個欄位缺值過半、存在不合理值；提出依 CRISP-DM 六階段的分析計畫與 repo 結構。
2. 資料集 A 分析	直接開始，網頁用 GitHub Pages	查到資料集的 Kaggle 來源；撰寫並執行 notebook：資料清理、缺值旗標、衍生特徵、one-hot 編碼；比較簡單線性回歸、全特徵 MLR，以及群組層級 Stepwise-AIC、RFE、LassoCV 三種特徵選擇；評估 R^2、RMSE、MAPE、5-fold CV、殘差、VIF；以 statsmodels 畫出含 95% 信賴區間與預測區間的預測圖（PI 覆蓋率 94.7%）。
3. 網頁部署與上傳	提供 GitHub repo，成果要推上去	製作 GitHub Pages 報告網頁與 JavaScript 線上估價器（瀏覽器端計算預測值與預測區間，並與 Python 結果交叉驗證）；撰寫 README、requirements.txt；提供 git 推送指令；網頁出現 404 時，說明需在 Settings → Pages 選擇 main 分支的 /docs 資料夾。
4. NotebookLM 研究	用 NotebookLM 研究網路上同主題解法	嘗試以瀏覽器開啟 NotebookLM（需作者自行登入 Google 帳號）；整理建議放入 NotebookLM 的研究來源與提示詞；說明 NotebookLM 與一般語言模型的差別：NotebookLM 屬於 RAG 系統，只根據使用者提供的來源回答並附上引用，幻覺風險較低。
5. 加入第二個資料集	新增 Human-AI Interaction 資料集，用相同格式做一個版本，網頁以下拉選單切換	先確認作者原本提出的 Kaggle 競賽（i3-ml-21-22-mini-project）需要邀請才能下載；改分析作者提供的人機互動信任資料（10,100 筆、20 個特徵）：刪除重複值、修正負的錯誤率、先切分再填補缺值以避免洩漏；Stepwise-AIC 從 20 個特徵保留 9 個，R^2 0.695，PI 覆蓋率 95.4%；發現準確率與錯誤率共線（VIF ≈ 16）；網頁加入資料集下拉選單與信任分數預測器。
6. 報告整合	產生給 NotebookLM 看的專案說明 PDF，並把 NotebookLM 摘要放進報告	產生本 PDF；將 NotebookLM 摘要放入網頁與本 PDF 並標示來源；提醒作者核對 NotebookLM 引用的研究是否真的存在、內容是否與原文相符。

8. NotebookLM 摘要：網路上同主題解法之研究摘要與比較

> **【NotebookLM 摘要】**以下內容由 Google NotebookLM 生成（來源：本專案說明與網路上同主題的研究／解法），作者僅轉換格式，未修改文字內容。

針對網路上關於房價預測與 AI 信任度多元線性回歸（Multiple Linear Regression, MLR）的相關解法，研究重點與成果彙整如下：

1. 房價預測與特徵選擇（Dataset A 主題）

- **資料轉譯與洩漏防範**：根據 IDEAS/RePEc 與 Marmara University 的研究，網路上針對土耳其及伊斯坦堡房地產資料集建模時，普遍採用對數轉換（log transformation）來平滑高通膨導致的房價右偏現象，並強調必須剔除每平方米單價（price per square meter）等衍生指標，避免產生資料洩漏（data leakage）。
- **特徵選擇方法**：TCSISR 的研究比較了 Stepwise AIC、Lasso 與 Elastic Net 在高維度房屋屬性上的表現。研究指出，地段（行政區 dummy 變數）與房屋淨面積對數是影響房價最具解釋力的特徵；利用正則化回歸（Lasso）或 Stepwise AIC 能有效降低變數維度與多重共線性問題，與本專案 Stepwise AIC 篩選後維持 $R^2 \approx 0.803$ 的結論完全一致。

2. 人機互動與 AI 信任度預測（Dataset B 主題）

- **關鍵預測因子分析**：Journal of Archetype 發表針對 Kaggle 人機互動資料集的多元回歸分析顯示，個人的**信任歷史（trust_history, β = .485）**是影響 AI 信任度的最強正向因子，而**認知負荷（cognitive_load, β = −.151）**與系統錯誤率則會顯著降低信任度，整體模型解釋力落在 25%–30% 之間。
- **技術與情境屬性**：arXiv 的大規模實驗亦證實，系統的模型準確率（accuracy）、偏誤程度與介面複雜度（UI complexity）是決定信任度的核心技術因素；相反地，使用者的年齡、技術經驗等個人人口統計變數對信任度的影響極微，此結論與本專案 Stepwise AIC 剔除人口變數後的結果高度吻合。

核心觀察與建議：網路上同主題研究印證了本專案在 CRISP-DM 流程中的決策正當性，包括利用群組化特徵選擇保持類別變數完整性、避免資料洩漏，以及採用預測區間（Prediction Intervals）呈現單一物件或分數的不確定性。這份網路研究摘要可直接引用納入專案報告的相關工作（Related Work）或討論章節中。